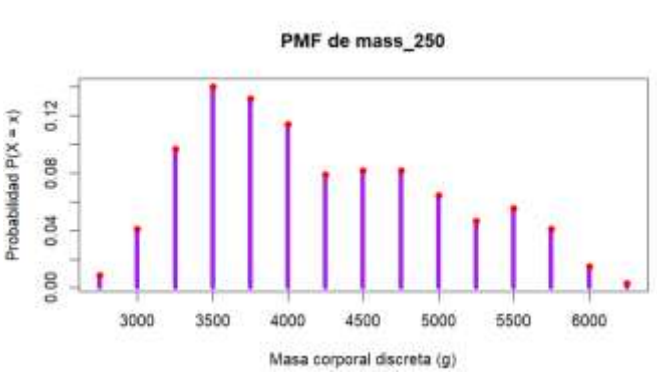
Tarea 02 – Estadística Inferencial

Distribuciones Empíricas y Generación de Muestras en R

Parte # 1 – Distribución de una variable discreta

A continuación, se muestra la tabla de frecuencias y gráfica PMF obtenidas a partir de los datos discretos analizados en el programa de trabajo:




```
[1] "Tabla distribucion (tabla 1)"
> print(tabla_1)
   Soporte_x Frecuencia_n   PMF_P_X_x    CDF_F_x
1       2750           3 0.008771930 0.00877193
2       3000          14 0.040935673 0.04970760
3       3250          33 0.096491228 0.14619883
4       3500          48 0.140350877 0.28654971
5       3750          45 0.131578947 0.41812865
6       4000          39 0.114035088 0.53216374
7       4250          27 0.078947368 0.61111111
8       4500          28 0.081871345 0.69298246
9       4750          28 0.081871345 0.77485380
10      5000          22 0.064327485 0.83918129
11      5250          16 0.046783626 0.88596491
12      5500          19 0.055555556 0.94152047
13      5750          14 0.040935673 0.98245614
14      6000           5 0.014619883 0.99707602
15      6250           1 0.002923977 1.00000000
```

Datos obtenidos:

P(3500 <= X <= 4500) = 0.5467836

Valor Esperado E[X] : 4208.33 g

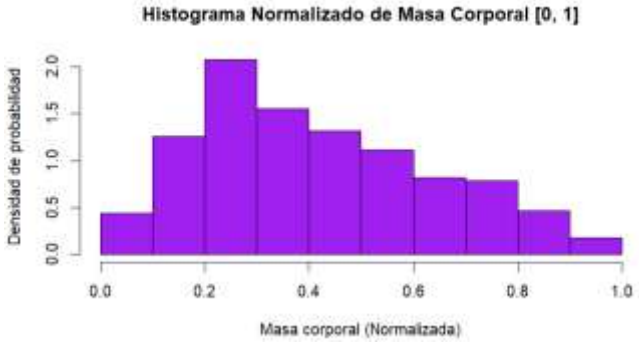
Var(X): 641356 g^2

Pregunta: ¿Por qué el valor esperado obtenido desde la PMF debe coincidir con la media mass_250?

Coinciden porque ambas operaciones hacen exactamente lo mismo, calculan un promedio. Al obtener el valor esperado con la PMF, multiplicamos cada peso por la proporción de veces que aparece en los datos. Esto es igual al sumar todos los datos redondeados y dividirlos entre el total de pingüinos. Como es exactamente la misma operación, solo expresada de otra forma, el resultado tiene que ser igual.

Parte # 2 – Representación de una variable continua

A continuación, se muestra el histograma generado a partir de las variables continuas:

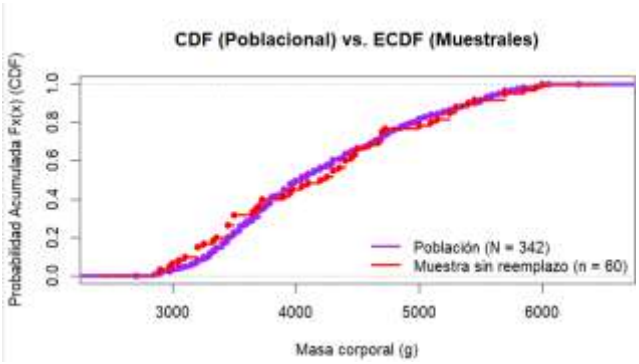


Pregunta: ¿Por qué la normalización min-max modifica la escala, pero conserva la información y la probabilidad de eventos equivalentes? Señale además por qué, en el histograma normalizado, la probabilidad está representada por el área de las barras

La normalización solo acomoda o reduce los datos para que entren en un rango de 0 a 1 ([0, 1]. Como no cambia el orden de los pingüinos ni la cantidad que hay en cada grupo, la proporción de datos en un rango equivalente sigue siendo la misma antes y después del cambio de escala.

En el histograma, la altura de cada barra representa la densidad (la proporción de datos dividida entre el ancho de la barra). Al calcular el área (base × altura), el ancho se cancela y nos devuelve la proporción de datos del intervalo. Por eso, el área de cada barra es la probabilidad y la suma de todas las áreas da 1.

Parte # 3 - CDF de la población y ECDF de una muestra

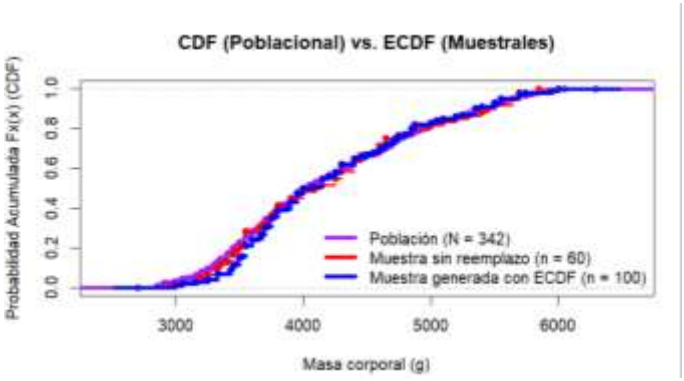


Pregunta: Interprete ambos resultados y explique por qué no coinciden exactamente.

El resultado de Fprob(4000) = 0.4971, significa que el 49.71% de todos los pingüinos pesan 4000 gramos o menos, pero Fn(4000) = 0.45 nos indica que, en nuestro grupo seleccionado de 60 pingüinos, el 45% pesa 4000 gramos o menos.

Varían porque no son idénticos debido al azar al tomar la muestra. Un grupo pequeño de 60 pingüinos no siempre refleja a toda la población a la perfección, pero si tomáramos una muestra más grande, el resultado se va acercando cada vez más al valor poblacional.

Parte # 4 - Generación mediante la función cuantil empírica



Pregunta: ¿Qué significa generar una nueva muestra desde la ECDF y por qué este procedimiento no produce información nueva sobre la población?

Esto se interpreta como meter los pesos de los pingüinos originales a una bolsa y sacar 100 números al azar, regresando el papelito a la bolsa cada vez que sacamos uno (muestreo con reemplazo). Esto no genera nada nuevo porque no inventa pesos que no hayamos registrado antes ni asume cómo se comportan los pingüinos en general; únicamente se reutilizan los mismos valores que ya teníamos en la base de datos original.